

ML이해/분석활용

ML for Analysis

1. 제조 도메인 데이터 이해 및 탐색



한화시스템

DAY 1

제조 도메인 데이터 이해 및 탐색

공장 데이터, 어디서부터 봐야 하나?




ML이해/분석활용 [Level.3] · 6일 과정 · 1일차 · 8교시



진행 순서

오늘의 현장 질문

공장 데이터, 어디서부터 봐야 하나? 흠어진 데이터를 모아 살펴보고, 화면으로 만듭니다.



오늘의 결과물: 분석 테이블 → EDA 결과 → SPC 모니터링 앱



한눈에 비교

오늘의 일정

매 교시 이론 15분 + 실습·활동 30분 + 휴식 15분입니다.

교시	주제	교시	주제
1	과정 소개 · ML 프로세스	5	Data Type · EDA 체크리스트
2	데이터 핸들링 · 분석환경	6	시각화
3	ML 활용 사례 · 파생변수	7	Streamlit · SPC 관리도
4	데이터 포맷 · DuckDB	8	하루 정리 · 과제 1 안내


실습은 노트북에 직접 입력하고, 2·3교시는 토론으로 진행합니다.



진행 순서

6일 로드맵

매주 하루, 제조 문제 하나를 끝까지 푼다.



일차마다 현장 질문이 하나씩 있고, 하루 안에 완결됩니다.



핵심 개념

수업 방식

짧게 듣고, 길게 해 봅니다.

01

한 교시 60분

- 이론 15분 · 실습 30분
- 휴식 15분
- 해석 중심으로 진행

02

하루 완결

- 지난주 결과물 없이 시작
- 데이터를 처음부터 불러옴
- 결석해도 따라올 수 있음

03

과제 운영

- 1~5일차 끝에 하나씩
- 6일차는 팀 발표
- 과제는 다음 수업의 전제가 아님

핵심 개념

분석 vs 머신러닝

분석은 과거를 설명하고, ML은 미래를 예측합니다.

01

분석

- "왜 불량이 났나?"
- 사람이 규칙을 찾음
- 예: 온도 > 80°C면 경고

02

머신러닝

- "다음에 불량이 날까?"
- 데이터에서 규칙을 학습
- 예: 온도·토크·마모의 조합 규칙


ML도 분석의 연장입니다. 규칙을 사람이 쓰느냐, 데이터가 알려 주느냐의 차이입니다.

진행 순서

ML 프로세스

모델 학습은 전체 과정의 한 칸일 뿐입니다. 시간 대부분은 그 앞 단계에 쓰입니다.

시간의 대부분이 여기에 쓰인다



오늘은 1~3단계와 7단계(모니터링 앱)를 다룹니다.

핵심 개념

AI 코딩 어시스턴트 활용

AI는 초안 작성자, 검증은 사람 몫입니다.

01

잘 묻는 법

- 컬럼·타입과 목표를 함께
- 작은 단위로 요청
- 에러 메시지를 그대로 붙여넣기

02

검증 습관

- shape·head 먼저 확인
- 결과 수치를 상식으로 점검
- 코드를 직접 읽어 보기

03

보안


- 사내 원본 데이터 업로드 주의
- 컬럼명·샘플로 대신 설명
- 회사 보안 규정 확인



진행 순서

왜 가상환경인가

프로젝트마다 독립된 작업실을 만들어 라이브러리 버전 충돌을 막습니다.



이 과정은 PyCaret 호환을 위해 Python 3.11을 씁니다.



한눈에 비교

데이터 핸들링 5원칙


원본은 건드리지 않습니다.

원칙	뜻	어기면 생기는 일
① 원본 보존	원본은 수정하지 않는다	처리 실수를 되돌릴 수 없음
② 코드로 처리	손으로 고치지 않고 코드로 남긴다	같은 결과를 다시 만들 수 없음
③ 데이터 사전	컬럼 의미와 단위를 적어 둔다	숫자의 뜻을 오해함
④ 시간 기준 통일	시간대·기록 시점(시작/끝) 통일	시간이 어긋난 채 조인됨
⑤ 단계 분리	raw → clean → mart로 나눠 저장	어느 단계 문제인지 못 찾음

진행 순서

제조 분석환경 아키텍처

위로 올라갈수록 데이터는 요약됩니다.



계층마다 데이터 주기가 다르므로, 어느 계층의 데이터인지 먼저 확인하세요.

한눈에 비교

분석서버 H/W 요건

정형 데이터 ML은 GPU보다 메모리가 먼저입니다.

자원	필요한 정도	이유
메모리	가장 먼저 부족해짐	pandas는 복사본을 만들어 데이터 크기의 수 배 필요
CPU 코어	많을수록 유리	교차검증.튜닝을 병렬로 돌림
GPU	정형 ML에는 대개 불필요	딥러닝.이미지에 필요
저장	SSD + Parquet	읽기 속도와 용량 절감

경험칙: 노트북 → 워크스테이션 → 서버 순으로 데이터 규모에 맞춰 올립니다.

핵심 개념

전수 데이터 vs 샘플링

전수는 정확하지만 비용이 큼니다. 샘플링은 어떻게 뽑느냐가 결과를 바꿉니다.

01

단순 무작위

- 표본 선택이 간단
- 드문 불량이 빠질 수 있음

02

층화

- 불량 비율을 유지
- 드문 사건에 적합

03

시간 기반

- 기간의 대표성 확보
- 교대조·계절 편향 방지

핵심 숫자

샘플링의 함정

드문 사건은 샘플링하면 사라집니다.

전체 데이터

100만 건

불량률 0.5%

무작위 1% 샘플

1만 건

불량은 약 50건만 남음

교대조·계절 편향, 특정 설비 누락도 같은 방식으로 결과를 바꿉니다.

핵심 개념

제조 ML 활용 지도

제조 ML 문제는 6가지로 정리됩니다. 입력과 출력을 먼저 정합니다.

01

설비 상태

- 예지보전 (3일차)
- 이상탐지
- 입출력: 센서 → 고장 신호

02

품질

- 품질 예측·가상계측 (4일차)
- 불량 분류 (3일차)
- 입출력: 공정값 → 품질·불량

03

수요·자원

- 생산량·수요 예측
- 에너지 예측 (5일차)
- 입출력: 과거 실적 → 미래 수치

핵심 개념

현장 질문을 ML 문제로

"내일 설비 A가 멈출까?"를 ML 문제로 바꾸면 세 가지가 정해집니다.

01

무엇을 (y)

- 예측할 대상
- 예: 24시간 내 고장 여부

02

무엇으로 (X)

- 예측에 쓸 정보
- 예: 최근 센서 통계

03

언제 예측

- 예측하는 시점
- 예: 매일 오전 8시

한눈에 비교

제조 데이터 유형

데이터마다 주기와 형식이 다릅니다.

데이터 유형	주기	크기	대표 형식
센서 시계열	초~분	매우 큼	Parquet · 시계열 DB
공정 파라미터(설정값)	변경 시	작음	DB 테이블 · CSV
검사·품질	제품·LOT별	중간	DB 테이블
생산실적(MES)·설비 이력	건별·일별	중간	DB · CSV
알람·이벤트 로그	발생 시	큼	텍스트 로그 · JSON

핵심 개념

데이터를 잇는 열쇠

여러 데이터를 이을 때는 세 가지 키를 씁니다.

01

시간

- 센서 1초 vs 실적 1일
- 집계해서 해상도 맞추기

02

설비 ID

- 어느 설비의 값인지
- 설비 마스터와 연결

03

제품(LOT) ID

- 어느 제품의 값인지
- 품질 결과와 연결

조인 키 3종: 시간 · 설비ID · 제품(LOT)ID

핵심 개념

파생변수: 현장 지식을 숫자로

원본 컬럼보다 의미 있는 조합이 고장을 설명합니다.

01

동력

- 토크 × 회전속도
- 전력 고장(PWF)과 연결

02

온도차

- 공정온도 - 공기온도
- 열 방출 고장(HDF)과 연결

03

과부하

- 공구 마모 × 토크
- 과부하 고장(OSF)과 연결

좋은 파생변수 하나가 복잡한 모델보다 낫습니다. 현장 지식이 곧 피쳐입니다.

한눈에 비교

파생변수 유형 정리

시간 · 누적 · 비율 · 범주 · 이벤트로 나눠 생각합니다.

유형	예	현장 의미
시간	lag, 이동평균, 이동표준편차, 차분	흐름과 변동을 숫자로
누적	누적 가동시간, 공구 사용시간	얼마나 오래 썼나
비율·차이	온도차, 동력 비율	두 값의 관계
범주	교대조, 요일	언제·누가 만들었나
이벤트	마지막 정비 후 경과시간	마지막 사건 이후 얼마나

한눈에 비교

4가지 데이터 포맷

같은 데이터라도 저장 형식에 따라 크기와 읽는 속도가 달라집니다.

포맷	저장 방식	장점	주의할 점
CSV	텍스트 · 행 단위	어디서나 열린다	타입 정보 없음, 용량 큼
JSON	텍스트 · 중첩 구조	API·설정에 적합	표로 펼쳐야 함
Parquet	바이너리 · 열 단위	압축, 빠른 읽기, 타입 보존	텍스트로 볼 수 없음
DB 테이블	서버·파일 DB	SQL, 동시 접근, 관리	접속·권한 관리 필요

저장은 Parquet, 조인·집계는 SQL로 하면 빠르고 단순합니다.

핵심 개념

행 지향 vs 열 지향

분석은 열 단위로 읽습니다. 그래서 Parquet이 빠릅니다.

01

행 지향 (CSV·DB)

- 한 행을 통째로 저장
- 한 건 읽고 쓰기에 유리
- 열 하나만 읽어도 전체를 훑음

02

열 지향 (Parquet)

- 열 단위로 모아 저장
- 필요한 열만 읽어 빠름
- 같은 값이 모여 압축이 잘 됨

핵심 개념

pandas로 읽고 쓰기

읽을 때 타입과 인코딩을 정합니다. 코드는 노트북 D1_04에서 입력합니다.

01

CSV 읽기

- read_csv로 읽기
- parse_dates로 날짜 지정
- 현장 CSV는 cp949가 흔함

02

JSON 펼치기

- json_normalize 사용
- sep="_"로 이름 연결
- 예: spec_maker 컬럼

03

Parquet

- read_parquet로 읽기
- to_parquet로 저장
- 타입이 그대로 보존

핵심 개념

DuckDB: 파일에 바로 SQL

파일과 DataFrame을 테이블처럼 쿼리합니다.

01

서버 없이

- 설치형 DB 서버가 없음
- 파일을 바로 쿼리
- 가볍게 시작

02

함께 조인

- 파일·DataFrame·DB 표를
- 한 SQL로 조인
- 결과는 .df()로 받음

03

큰 데이터


- 메모리보다 큰 데이터도
- 열 단위로 빠르게 집계
- Parquet와 궁합이 좋음

예: `con.sql("SELECT ... FROM 'sensor_log.parquet' s JOIN ...").df()`

구조 한눈에

오늘의 데이터: 가상 공장 번들

네 가지 형식의 파일을 세 개의 키로 이어 붙여, 분석에 쓸 표 하나를 만듭니다.



조인 전에 키의 형식(문자·숫자, 시간 단위)이 같은지 먼저 확인하세요.

핵심 개념

EDA란

모델보다 먼저 데이터와 대화합니다.

01

품질 확인

- 결측·중복·이상치
- 데이터를 믿기 전에 확인

02

패턴 발견

- 분포·그룹 차이·시간 추이
- 그림과 표로 훑어보기

03

가설 만들기

- "왜 이 설비만 높을까?"
- 검정·모델링의 출발점

한눈에 비교

데이터 타입 정리

타입이 틀리면 분석이 틀립니다.

종류	pandas 타입	잘못된 타입의 신호
수치 (연속·이산)	float64 · int64	숫자인데 object (coma·단위 문자)
범주 (명목·순서)	category · object	코드 숫자를 수치로 오해
날짜시간	datetime64	날짜가 문자열(object)로 읽힘

`read_csv`의 `parse_dates`로 날짜를 처음부터 날짜 타입으로 읽으세요.

한눈에 비교

데이터 품질 점검

결측 · 중복 · 이상치 · 범위를 확인합니다.

점검	볼 것	제조 데이터에서는
결측	센서 끊김 vs 무작위	특정 설비·시간에 몰려 있는지 확인
중복	완전히 같은 행	같은 기록이 두 번이면 건수가 부풀려짐
이상치	센서 오류 vs 실제 이상	제조에서는 관심 대상일 수 있음
범위	물리적으로 가능한가	음수 온도, 0 rpm 같은 값

결측이 몇 개인지보다 어디에 몰려 있는지가 중요합니다.

핵심 개념

기술통계 읽는 법

describe() 한 줄로 평균, 흔들림, 범위를 한 번에 봅니다.

01

평균 vs 중앙값

- 다르면 분포가 치우침
- 예: rpm은 평균 > 중앙값

02

표준편차·사분위

- 흔들림의 크기
- 25%·75%로 중간 구간 확인

03

최소·최대

- 물리적으로 가능한가
- 오류값을 찾는 가장 빠른 길

핵심 개념

그룹 비교와 불량률

불량률은 분모부터 확인합니다.

01

건수 vs 비율

- 불량 건수는 생산량에 좌우
- 불량률 = 불량 ÷ 생산 건수

02

분모를 확인

- 생산량이 적은 그룹은 착시
- 예: 3건 중 1건 = 33%

설비별 고장 건수와 생산 건수를 groupby로 함께 봅니다.

한눈에 비교

EDA 체크리스트

매번 같은 순서로 10항목을 봅니다.

묶음	확인 항목	대표 코드
구조	크기 · 타입	shape, dtypes
품질	결측 · 중복 · 범위	isna(), duplicated(), describe()
분포	기술통계 · 범주 빈도 · 타깃 분포	describe(), value_counts()
비교·추이	그룹 비교 · 시간 추이	groupby(), resample()

10항목: 크기·타입·결측·중복·범위·기술통계·범주 빈도·타깃 분포·그룹 비교·시간 추이



핵심 개념

나를 위한 차트, 남을 위한 차트

차트는 질문에 맞춰 고르고, 결론은 제목에 씁니다.

01

탐색용

- 빠르게 많이 그린다
- 제목·색은 대충
- 질문을 찾는 용도

02

설명용

- 하나의 메시지
- 결론을 제목에 쓴다
- 강조색은 하나



한눈에 비교

질문별 차트 선택

질문이 차트를 정합니다.

질문	차트	예
분포	히스토그램 · 박스플롯	정상·고장의 토크 분포
비교	막대 · 박스플롯	설비별 고장률
관계	산점도 · 히트맵	회전수와 토크
추이	선그래프	주별 고장률
구성	누적 막대	고장 유형 비율

한눈에 비교

Seaborn 기본 문법

data · x · y · hue 네 가지면 대부분의 차트가 그려집니다.

인자	뜻	실습 예
data	그릴 표(DataFrame)	data=df
x · y	가로·세로 변수	x="rpm", y="torque"
hue	색으로 나눌 변수	hue="failure"
차트 함수	boxplot · barplot · scatterplot	sns.boxplot(...)

코드는 노트북 D1_06에서 직접 입력합니다. 박스플롯 → 막대 → 산점도 순서입니다.

한눈에 비교

제조 데이터 차트 패턴

자주 쓰는 네 가지 패턴입니다.

패턴	보여 주는 것	예
설비별 박스플롯	설비 간 분포 차이	설비별 토크
정상·고장 겹쳐 보기	고장 기록의 특징	hue="failure"
센서 상관 히트맵	함께 움직이는 센서	corr() 히트맵
시간 추이 + 이동평균	흐름과 이상 시점	주별 고장률

탐색용으로 네 가지를 먼저 그려 보고, 설명용으로 한 장만 다듬습니다.

핵심 개념

나쁜 차트, 좋은 차트

강조색 하나, 결론은 제목에 씁니다.

01

나쁜 차트

- 3D, 이중축 남용
- 색이 너무 많음
- 잘린 축

02

좋은 차트

- 결론형 제목
- 강조색은 하나
- 단위 표기

예: "오래된 설비 MC-03·MC-08의 고장률이 다른 설비의 2배"

핵심 개념

왜 모니터링 앱인가

분석 결과를 현장이 매일 보게 만듭니다.

01

일회성 보고서

- 한 번 보고 끝
- 다음 주면 낡음
- 보는 사람이 정해짐

02

매일 보는 화면

- 현장이 직접 확인
- 설비를 골라 비교
- 오늘 앱: KPI · 추이 · 관리도

진행 순서

Streamlit 동작 방식

파이썬 스크립트가 곧 웹앱입니다. 위젯을 바꾸면 전체가 다시 실행됩니다.



실행은 노트북이 아니라 터미널에서: `streamlit run app_spc.py`

한눈에 비교

Streamlit 핵심 요소

다섯 가지 요소로 대시보드를 만듭니다.

요소	하는 일	실습에서 쓰는 곳
st.title · st.metric	제목과 숫자 카드	생산 건수·고장률 카드
st.sidebar.selectbox	선택 상자	설비 선택 필터
st.line_chart · pyplot	추이·관리도 그래프	일별 추이, 관리도
st.dataframe	표 보여 주기	한계 이탈일 표
@st.cache_data	데이터 캐시	파일을 다시 읽지 않게

핵심 개념

SPC: 변동의 두 얼굴

우연원인은 두고, 이상원인은 잡습니다. 관리도는 평소와 다른지를 판정합니다.

01

우연원인

- 늘 있는 작은 흔들림
- 그대로 둔다
- 관리한계 안의 변동

02

이상원인

- 공구 마모, 설정 변경 등
- 찾아서 잡는다
- 한계 이탈·패턴으로 나타남

한눈에 비교

관리도 구성과 종류

중심선 $\pm 3\sigma$ 가 관리한계입니다. 종류는 데이터 모양으로 고릅니다.

관리도	쓰는 데이터	한계 계산
I-MR	개별값 (한 번에 하나)	$UCL = \bar{\bar{x}} + 2.66 \times M\bar{R}$
$\bar{\bar{X}}$ -R	부분군 (여러 개씩)	부분군 평균·범위로 계산
p	불량률 (일별 불량률)	$\bar{p} \pm 3 \cdot \sqrt{(\bar{p}(1-\bar{p})/n)}$

관리한계는 평소의 흔들림이고 규격한계는 고객 요구입니다. 둘은 다릅니다.

핵심 개념

이상 판정 규칙

한계 안이어도 패턴이면 이상입니다. 오늘 데이터에 드리프트가 숨어 있습니다.

01

규칙 ①

- 관리한계 이탈
- UCL 위 · LCL 아래
- 한 점만 나가도 이상

02

규칙 ②

- 중심선 한쪽에 연속 8점
- 기준에 따라 7~9점
- 서서히 치우치는 신호

03

규칙 ③


- 연속 6점 증가·감소
- 추세(드리프트) 신호
- 실습은 ①②만 구현



진행 순서

오늘 한 일

흩어진 데이터를 모아 살펴보고, 화면으로 만들었습니다.



ML 프로세스의 앞 단계(문제 정의 ~ EDA)와 마지막 단계(모니터링)를 다뤘습니다.



한눈에 비교

현장 적용 체크리스트

다음 주 화요일 전에 내 데이터로 해 볼 다섯 가지입니다.

순서	해 볼 일
1	데이터 흐름도 확인
2	데이터 사전 만들기
3	EDA 체크리스트 적용
4	파생변수 1개 만들기
5	관리도 1개 그리기

한눈에 비교

정리 퀴즈

오늘 배운 것을 다섯 문항으로 확인합니다.

#	질문
1	분석과 머신러닝은 어떻게 다른가?
2	Parquet의 장점은?
3	샘플링의 함정은?
4	질문별로 어떤 차트를 고르나?
5	관리한계와 규격한계는 어떻게 다른가?

핵심 개념

과제 1

수업에서 만든 분석 테이블과 SPC 앱을 확장합니다.

01

할 일

- 설비별 EDA 리포트
- 앱에 p 관리도 추가
- 한계는 일별 생산량으로

02

제출물

- EDA 노트북 (.ipynb)
- Streamlit 앱 (.py)
- 핵심 발견 3줄 요약

03

평가 포인트

- EDA 체크리스트를 따랐나
- 차트 제목에 결론이 있나
- 관리도를 바르게 해석했나

힌트: p 관리도는 일별 불량률을 점으로 찍고, 관리한계는 날마다 달라집니다.

핵심 개념

다음 시간: 2일차 예고

조건에 따라 품질이 정말 다른가?

01

통계 검정

- 상관 · t-test · ANOVA
- p-value 읽는 법

02

비지도 학습

- PCA · 요인분석
- 군집 · 연관규칙

03

모델링 준비

- Train / Test / Deploy
- 데이터 누수