

ML이해/분석활용

ML for Analysis

2. 통계분석과 비지도 학습



한화시스템

DAY 2

통계분석과 비지도 학습

조건에 따라 품질이 정말 다른가?




ML이해/분석활용 [Level.3] · 6일 과정 · 2일차 · 8교시



진행 순서

오늘의 현장 질문

차이를 확인하고, 패턴을 찾고, 모델링을 준비합니다.



오늘의 결과물: 검정 결과 해석 + 운전 모드 프로파일 + 누수 없는 데이터 분할



핵심 개념

지난 시간 핵심

오늘 필요한 1일차 개념 세 가지입니다. 1일차를 듣지 않아도 따라올 수 있습니다.

01

분석 테이블

- 세 개의 키로 조인
- 시간 · 설비ID · 제품ID
- 1행 = 생산 기록 1건

02

EDA 체크리스트

- 크기·타입·결측·중복
- 분포와 그룹 비교
- 매번 같은 순서로 확인

03

불량률은 분모부터

- 건수가 아니라 비율로
- 생산량이 적은 그룹은 착시

한눈에 비교

환경 점검

오늘 쓰는 패키지 다섯 개입니다. 설치가 끝났다면 import 한 번으로 확인합니다.

패키지	용도	쓰는 교시
scipy	상관·t-test·ANOVA 검정	1~3교시
statsmodels	ANOVA 사후검정(Tukey)	3교시
scikit-learn	PCA · K-means · 데이터 분할	3~7교시
factor_analyzer	요인분석	3교시
mlxtend	연관규칙(Apriori)	6교시

한눈에 비교

오늘의 일정

매 교시 이론 15분 + 실습·활동 30분 + 휴식 15분입니다.

교시	주제	교시	주제
1	통계분석 개요 · 상관 · 가설검정	5	프로파일링 · 군집 해석
2	t-test · A/B 테스트	6	연관성 분석
3	ANOVA · PCA · 요인분석	7	Train/Test·Deploy · 데이터 누수
4	비지도 학습 · 군집분석	8	하루 정리 · 과제 2 안내

통계 검정(1~3교시) → 비지도 학습(4~6교시) → 모델링 준비(7교시) 순서입니다.

핵심 개념

기술통계 vs 추론통계

가진 데이터를 요약하는 것과, 그 나머를 판단하는 것은 다릅니다.

01

기술통계

- 평균·분산·그래프
- 가진 데이터를 요약
- 1일차에 배움

02

추론통계

- 표본으로 모집단을 판단
- 검정과 추정
- 오늘 배움

예: 이번 달 1,000개로 "공정 전체"를 말할 수 있을까?

한눈에 비교

상관분석

상관계수는 -1~1입니다. 방향과 강도를 함께 봅니다.

구분	범위	해석
약함	0 ~ 0.3	거의 관계 없음
보통	0.3 ~ 0.7	어느 정도 함께 움직임
강함	0.7 이상	뚜렷하게 함께 움직임
부호	+ / -	+ 함께 증가, - 반대로 움직임

피어슨은 직선 관계, 스피어만은 순위(단조) 관계를 봅니다.

핵심 개념

상관은 인과가 아니다

함께 움직인다고 원인은 아닙니다.

01

숨은 공통 원인

- 외기 온도가 올라가면
- 공기·공정 온도가 함께 상승
- 서로가 원인은 아님

02

우연한 상관

- 관계없는 변수끼리도
- 우연히 높게 나올 수 있음

03

역인과


- 원인과 결과가 거꾸로
- 비선형은 상관 0이어도 관계 있음



진행 순서

가설검정의 논리

재판처럼: 무죄 추정 → 증거 → 판결입니다.



귀무가설 = "차이가 없다". p-value가 작으면 귀무가설을 기각합니다.



핵심 개념

p-value 바르게 읽기

p-value는 "차이가 없다면, 이 정도 결과가 나올 확률"입니다.

01

뜻

- 귀무가설이 맞다는 가정에서
- 이 결과가 나올 확률

02

흔한 오해

- 귀무가설이 맞을 확률이 아님
- 0.05는 절대 기준이 아님

03

기각 못 함

- "차이 없음 증명"이 아님
- 증거가 부족하다는 뜻

핵심 숫자

유의하다 ≠ 중요하다

표본이 크면 아주 작은 차이도 "유의"하게 나옵니다.

표본 크기

10 만 건

매우 큰 표본

평균 차이

0.1 °C

현장에서는 아주 작은 차이

p-value

<0.001

통계적으로는 유의

유의성과 함께 효과 크기(차이가 얼마나 큰가)를 꼭 말하세요.

한눈에 비교

t-test의 종류

비교 대상의 모양에 따라 고릅니다.

종류	상황	예	scipy 함수
1표본	목표값과 비교	평균 토크가 40 Nm인가	ttest_1samp
독립 2표본	서로 다른 두 그룹	설비 A vs 설비 B	ttest_ind
대응 표본	같은 대상의 전후	같은 설비의 개선 전후	ttest_rel

핵심 개념

t-test가 보는 것

평균 차이 ÷ 흔들림 = t값입니다.

01

평균 차이

- 클수록 t값이 커짐
- 차이가 확실해짐

02

흔들림

- 작을수록 t값이 커짐
- 데이터가 안정적일수록

03

표본 수


- 많을수록 t값이 커짐
- 전제: 정규성(표본 크면 완화)

등분산이 의심되면 **Welch t-test(equal_var=False)**를 씁니다.

진행 순서

A/B 테스트 설계

검정보다 설계가 먼저입니다.



설계가 잘못되면 검정을 잘해도 결론이 틀립니다.

한눈에 비교

평균 비교 vs 비율 비교

지표가 숫자냐 비율이냐에 따라 검정이 다릅니다.

지표	예	검정
평균	치수, 온도, 거칠기	t-test
비율	불량률	카이제곱 · 비율 검정
3개 이상 그룹	등급 L·M·H	ANOVA (3교시)

핵심 개념

제조 A/B 테스트의 함정

조건 말고 다른 것이 달라지면 비교가 무너집니다.

01

동시에 운영

- 같은 기간에 나눠 돌림
- 기간 차이 = 원료·계절 차이

02

하나만 바꾸기

- 한 번에 하나만 변경
- 원인을 좁힐 수 있음

03

같은 조건 비교

- 같은 설비
- 같은 교대조에서 비교

핵심 숫자

왜 t-test를 여러 번 하면 안 되나

비교 횟수가 늘면 "우연한 유의"도 늘어납니다.

쌍 비교 횟수

3 번

3그룹이면 3쌍

쌍마다 오류

5 %

유의수준 0.05

하나라도 틀릴 확률

14 %


$1 - 0.95^3$

그래서 ANOVA로 한 번에 검정합니다.

진행 순서

ANOVA와 사후검정

"어딘가 다르다"에서 "어디가 다른가"로 갑니다.



"차이 없음"도 중요한 결과입니다. 토크는 등급 간 차이가 없습니다.

핵심 숫자

차원 축소가 필요한 이유

센서가 너무 많으면 보이지 않습니다.

센서

590 개

SECOM 반도체 공정

생산 기록

1,567 건

변수가 관측치에 가까움

불량

104 건

전체의 약 6.6%

변수가 많으면 시각화·해석·모델링이 모두 어려워집니다.

핵심 개념

PCA: 정보를 담은 새 축

흩어짐이 가장 큰 방향으로 축을 다시 잡습니다.

01

개념

- 함께 움직이는 변수를
- 하나의 축으로 묶음

02

설명 분산

- 누적 80~90%까지
- 몇 개의 축이 필요한가

03

주의

- 스케일링 필수
- 축의 의미는 사람이 해석

한눈에 비교

PCA vs 요인분석

요약이 목적이면 PCA, 숨은 원인을 찾으면 요인분석입니다.

항목	PCA	요인분석
목적	정보를 압축	숨은 원인(잠재 요인) 찾기
결과	주성분(새 축)	요인과 적재량
해석	축의 의미는 사람이 붙임	요인에 이름을 붙임
제조 활용	압축·시각화·모델 입력	크기·밝기·형태 같은 요인

실습: SECOM은 PCA, Steel Plates는 요인분석입니다.

핵심 개념

요인분석 결과 읽기

적재량이 큰 변수를 보고 요인에 이름을 붙입니다.

01

요인 적재량

- 변수와 요인의 관계 강도
- 0.4 이상 변수를 본다

02

이름 붙이기

- 크기 관련 변수 → "결함 크기"
- 밝기 관련 변수 → "결함 밝기"

03

요인 수

- 고유값 1 이상
- 스크리 그림으로 확인

핵심 개념

지도 학습 vs 비지도 학습

정답이 있으면 지도, 없으면 비지도입니다.

01

지도 학습

- 고장 여부 같은 라벨로 학습
- 3·4일차에서 다룸

02

비지도 학습


- 라벨 없이 구조를 발견
- 오늘: PCA · 군집 · 연관규칙

제조 현장은 라벨이 부족한 경우가 많아 비지도 학습이 쓸모 있습니다.

진행 순서

K-means 동작 방식

중심을 정하고, 가까운 것끼리 묶고, 중심을 옮깁니다.



중심이 더 이상 움직이지 않으면 끝납니다.

핵심 개념

군집 수(k) 정하기

숫자 지표와 현장 해석을 같이 봅니다.

01

엘보

- 오차 감소가 꺾이는 곳
- 뚜렷하지 않을 수 있음

02

실루엣

- 군집이 잘 분리됐는가
- $-1 \sim 1$, 클수록 좋음

03

현장 해석

- 이름을 붙일 수 있는가
- 너무 많으면 쓸모 없음

핵심 숫자

스케일링은 필수

단위가 큰 변수가 거리를 지배합니다.

회전속도

1,500 rpm

수천 단위

공정온도

30 °C

수십 단위

토크

40 Nm

수십 단위

스케일링 없이는 회전속도가 군집을 결정합니다. 표준화(StandardScaler)를 먼저 합니다.

핵심 개념

K-means의 한계

등근 덩어리를 가정합니다.

01

모양 가정

- 길쭉하거나 휘어진 군집에 약함
- 대안: 계층적 군집, DBSCAN

02

이상치

- 이상치에 민감
- 중심이 끌려감

03

시작점


- 시작점에 따라 결과가 달라짐
- 여러 번 실행해 확인



진행 순서

프로파일링이란

군집은 번호가 아니라 이름이 붙어야 쓸모가 있습니다.



군집 번호(0, 1, 2) 자체에는 의미가 없습니다.



한눈에 비교

프로파일 표 읽기

전체 평균보다 높고 낮은 것으로 성격을 정합니다.

군집	회전속도	토크	공정온도	고장률	이름
0	1,470 rpm	43.7 Nm	38.1 °C	5%	고온 운전
1	1,474 rpm	43.3 Nm	35.6 °C	2%	저온 운전
2	1,796 rpm	26.6 Nm	37.0 °C	2%	고속·저부하 운전
전체	1,539 rpm	40.0 Nm	36.9 °C	3%	-

예시 수치입니다. 실습 결과와 조금 다를 수 있습니다.

한눈에 비교

군집 시각화 방법

목적에 따라 차트를 고릅니다.

목적	차트
군집별 평균 비교	막대 · 히트맵(표준화 평균)
분포 비교	박스플롯
군집 분리 확인	PCA 2D 산점도
시간 흐름	군집 라벨의 주별 비중

핵심 개념

군집 결과의 현장 활용

운전 모드별로 다르게 관리합니다.

01

모드별 관리

- 같은 SPC 한계를
- 모든 모드에 쓰지 않기

02

이상 군집

- 이상 군집은
- 이상탐지 후보

03

모델 피처

- 군집 번호를
- 3일차 모델의 피처로

핵심 개념

연관성 분석이란

장바구니 분석을 공장에 적용합니다.

01

유통

- 빵을 사면 우유도 산다
- 장바구니 분석

02

제조

- 고토크 + 고마모일 때
- 과부하 고장이 함께 나타남

03

결과물

- "A이면 B" 형태의 규칙
- 단서를 찾는 도구

한눈에 비교

세 가지 지표

얼마나 자주, 얼마나 확실히, 우연보다 얼마나 일어나는가입니다.

지표	뜻	읽는 법
지지도	A와 B가 함께 일어난 비율	얼마나 자주
신뢰도	A일 때 B가 일어난 비율	얼마나 확실히
향상도	신뢰도 ÷ B의 전체 비율	1보다 크면 의미 있는 연관

핵심 숫자

숫자로 보는 규칙

향상도가 우연 대비 몇 배인지 알려 줍니다. (1,000건 기준 예시)

지지도

3.0 %

A·B가 함께 30건

신뢰도

30 %

A 100건 중 B 30건

향상도

7.5 배


B 전체 비율 4% 대비

향상도 = 신뢰도 30% ÷ B의 전체 비율 4% = 7.5배입니다.

진행 순서

Apriori 분석 흐름

연속값은 먼저 구간으로 바꿉니다.



고장은 드물어서 최소 지지도를 낮게(0.3%) 잡습니다.

핵심 개념

규칙 해석의 주의점

규칙은 원인이 아니라 단서입니다.

01

인과 아님

- 상관과 같은 주의
- "함께 일어난다"일 뿐

02

구간 기준

- 나누는 방법에 따라
- 결과가 달라짐

03

낮은 지지도

- 지지도가 너무 낮으면
- 우연일 수 있음

핵심 개념

왜 데이터를 나누나

시험 문제를 미리 보면 실력을 알 수 없습니다.

01

Train

- 공부하는 데이터
- 모델을 학습

02

Valid

- 모의고사
- 튜닝에 사용

03


Test

- 실제 시험
- 마지막에 한 번만

구조 한눈에

학습에서 배포까지

과거 데이터는 나누고, 미래 데이터는 운영에서 들어옵니다.



실습에서는 4월 1일 이후 1,000건을 Deploy로 따로 떼어 둡니다.

한눈에 비교

분할 방법 고르기

데이터 성격에 맞게 나눕니다.

분할	쓰는 때	주의
무작위 분할	서로 독립적인 기록	시간 순서가 있으면 누수
층화 분할	불량처럼 드문 클래스	비율을 같게 맞춰 나눔
시간 기준 분할	시계열·운영 예측	과거로 학습, 미래로 평가

핵심 개념

데이터 누수 세 가지

누수가 있으면 성능이 비현실적으로 좋게 나옵니다.

01

타깃 누수

- 정답을 담은 컬럼
- 예: 고장 후 기록되는 정비 코드

02

시간 누수

- 미래 데이터로 과거를 예측
- 무작위 분할이 대표 원인

03


전처리 누수

- 전체로 스케일링한 뒤 분할
- Test 정보가 기준에 섞임

진행 순서

전처리는 Train에서만 배운다

fit은 Train, transform은 모두에 적용합니다.




스케일러의 평균·표준편차는 Train으로만 정합니다.



진행 순서

오늘 한 일

차이를 확인하고, 축을 줄이고, 패턴을 찾고, 모델링을 준비했습니다.



한눈에 비교

현장 적용 체크리스트

다음 수업 전까지 내 데이터로 해 볼 다섯 가지입니다.

순서	해 볼 일
1	상관 히트맵 그리기
2	개선 전후 t-test 해 보기
3	그룹 비교에 ANOVA 쓰기
4	운전 조건 군집 후 이름 붙이기
5	누수 의심 컬럼 찾기

한눈에 비교

정리 퀴즈

오늘 배운 것을 다섯 문항으로 확인합니다.

#	질문
1	p-value의 뜻은?
2	유의성과 효과 크기는 어떻게 다른가?
3	t-test를 여러 번 하면 안 되는 이유는?
4	K-means 전에 스케일링을 하는 이유는?
5	데이터 누수의 예를 하나 들어 보세요.

핵심 개념

과제 2

수업에서 배운 검정과 군집을 직접 해석합니다.

01

할 일

- 등급별 ANOVA 해석
- 군집 수 k를 바꿔 프로파일 비교
- factory_table.parquet 사용

02

제출물

- 분석 노트북 (.ipynb)
- 운전 모드 이름과 근거
- 핵심 발견 3줄 요약

03

평가 포인트

- p-value를 바르게 해석
- 효과 크기를 언급
- 군집 이름에 근거가 있나

ANOVA 결과가 "차이 없음"이어도 괜찮습니다. 해석이 바른지를 봅니다.

핵심 개념

다음 시간: 3일차 예고

설비 고장을 미리 알 수 있을까?

01

분류 모델

- 혼동행렬
- 정밀도 · 재현율

02

불균형 데이터

- 리샘플링 · SMOTE
- 클래스 가중치

03

준지도 · 튜닝

- Self-Training
- 교차검증 · 임계값

3일차도 데이터를 새로 불러와 시작합니다. 오늘 결과물이 없어도 참여할 수 있습니다.