

ML이해/분석활용

ML for Analysis

3. 지도학습 : 분류와 불균형



한화시스템

DAY 3

지도학습: 분류와 불균형

설비 고장을 미리 알 수 있을까?




ML이해/분석활용 [Level.3] · 6일 과정 · 3일차 · 8교시



진행 순서

오늘의 현장 질문

평가 기준부터 세우고, 데이터를 다듬고, 모델을 개선합니다.



오늘의 결과물: 고장 예측 모델 + 팀 워크숍 결과



핵심 개념

지난 시간 핵심

오늘 필요한 2일차 개념 세 가지입니다.

01

데이터 분할

- Train · Valid · Test
- 시간 기준으로 나눔

02

데이터 누수

- 타킷 · 시간 · 전처리
- 성능이 비현실적으로 좋아짐

03

fit은 Train에서만

- 전처리 기준은 Train으로
- Test·Deploy에는 transform

한눈에 비교

환경 점검

오늘 쓰는 패키지입니다.

패키지	용도	쓰는 교시
scikit-learn	모델 · 교차검증 · 튜닝 · 준지도	전 교시
imbalanced-learn	SMOTE · 리샘플링 Pipeline	2교시~
matplotlib · seaborn	혼동행렬 · 곡선 시각화	1.5교시

한눈에 비교

오늘의 일정

오전은 이론과 실습, 오후는 팀 워크숍입니다.

교시	주제	교시	주제
1	분류 모형 · 혼동행렬	5	하이퍼파라미터 · 임계값
2	불균형 · 리샘플링	6	워크숍 안내 (SECOM)
3	Data Mart 설계	7	워크숍 중간 점검
4	준지도 학습	8	하루 정리 · 과제 3 안내

매 교시 이론 15분 + 실습·활동 30분 + 휴식 15분입니다.

핵심 개념

분류 문제란

정답이 범주인 예측 문제입니다.

01

이진 분류

- 고장 / 정상
- 오늘 실습의 중심

02

다중 분류

- 결함 유형 7종 등
- Steel Plates 심화 과제

03

확률 → 판정

- 모델의 출력은 확률
- 임계값으로 판정

한눈에 비교

대표 분류 모델

해석이 쉬운 모델부터 시작합니다.

모델	특징	주의
로지스틱 회귀	확률 해석, 선형 경계	곡선 관계에는 약함
의사결정나무	규칙으로 설명	과대적합이 쉬움
랜덤포레스트	성능이 안정적 (6일차 상세)	설명이 어려움

핵심 숫자

정확도 96%의 함정

아무것도 안 해도 정확도가 96%입니다.

전체 데이터

10,000 건

AI4I 생산 기록

고장

339 건

전체의 3.4%

"모두 정상" 정확도

96.6 %

고장은 하나도 못 잡음

전체 기간 기준입니다. 실습의 평가 기간(마지막 20%)은 고장이 더 적어 98.1%입니다.

한눈에 비교

혼동행렬

맞고 틀린 것을 네 칸으로 나눕니다.

	예측: 고장	예측: 정상
실제: 고장	TP · 잡아냄	FN · 놓침
실제: 정상	FP · 오경보	TN · 정상 통과

놓침(FN)과 오경보(FP)는 서로 맞바꾸는 관계입니다.

핵심 개념

정밀도 vs 재현율

오경보와 놓침은 서로 맞바꿉니다.

01

정밀도

- $TP \div (TP + FP)$
- 오경보 비용과 관련
- 높을수록 헛경보가 적음

02

재현율

- $TP \div (TP + FN)$
- 놓침 비용과 관련
- 높을수록 고장을 많이 잡음

03

F1

- 정밀도·재현율의 조화평균
- 둘의 균형을 한 숫자로
- 한쪽만 높으면 낮아짐

한눈에 비교

현장 비용으로 지표 고르기

지표는 모델 전에 현장과 정합니다.

상황	고를 지표	예
놓침이 비쌘	재현율	라인 정지, 안전 사고
오경보가 비쌘	정밀도	불필요한 정비·검사
둘 다 중요	F1 · PR-AUC	균형이 필요한 경우

예: 고장을 놓치면 라인이 4시간 멈추고 헛경보는 10분이면 끝난다면 재현율을 먼저 봅니다.

핵심 개념

불균형 데이터가 어려운 이유

모델은 다수에 맞춰집니다.

01

다수에 치우침

- 정상이 96%라 정상만 맞히면 됨
- 소수(고장)는 뒷전

02

학습 부족

- 소수 패턴을 배울 기회가 적음
- 고장 339건뿐

03

정확도 착시

- 정확도가 높아도
- 고장은 못 잡을 수 있음

한눈에 비교

대응 방법 세 가지

데이터, 가중치, 임계값입니다.

방법	하는 일	주의
리샘플링	데이터 비율을 조정	Train에만 적용
클래스 가중치	<code>class_weight="balanced"</code>	정밀도가 떨어짐
임계값 조정	판정 기준을 낮춤 (5교시)	Valid에서 결정

핵심 개념

Over vs Under vs SMOTE

늘리거나, 줄이거나, 만들어 냅니다.

01

Under

- 정상을 줄임
- 빠르지만 정보 손실

02

Over

- 고장을 복제
- 과대적합 위험

03


SMOTE

- 이웃 고장 사이에 새 점 생성
- 단순 복제보다 다양함

진행 순서

리샘플링은 Train에만

평가 데이터는 현실 비율 그대로 둡니다.



imblearn Pipeline을 쓰면 리샘플링이 학습 데이터에만 적용됩니다.

핵심 개념

과소적합 vs 과대적합

너무 단순하거나, 너무 외웁니다.

01

과소적합

- 너무 단순
- Train·Test 모두 낮음

02

적정

- Train·Test 모두 좋음
- 두 점수의 차이가 작음

03

과대적합

- 너무 많이 외움
- Train만 높고 Test는 낮음

한눈에 비교

Train·Test 점수로 진단하기

두 점수의 차이를 봅니다.

Train	Test	진단	대응
낮음	낮음	과소적합	모델 복잡도를 올림
높음	낮음	과대적합	복잡도 낮춤 · 규제 · 데이터 추가
높음	높음	적정	그대로 사용, Test는 한 번만

실습: 끝까지 키운 나무는 Train F1 1.00, Test 0.58로 과대적합입니다.

핵심 개념

데이터 분할 복습

2일차 핵심을 한 장으로 요약합니다.

01

Train·Valid·Test

- 학습 · 튜닝 · 최종 평가
- Test는 마지막에 한 번

02

시간 기준 분할

- 과거로 학습
- 미래로 평가

03

전처리

- fit은 Train에서만
- Test에는 transform

오늘 실습은 편의상 전체 데이터의 마지막 20%를 Test로 씁니다(2일차 Deploy 기간 포함). 현장에서는 Deploy를 따로 둡니다.

구조 한눈에

Data Mart란

흩어진 데이터를 모델링용 표 하나로 만듭니다.



모델을 바꾸기 전에 데이터(Data Mart)를 먼저 바꿔 봅니다.

핵심 개념

설계의 세 가지 질문

단위, 시점, 라벨을 정하고 시작합니다.

01

단위

- 1행은 무엇인가
- 오늘: 생산 기록 1건

02

시점

- 언제 예측하나
- 오늘: 생산 직전

03

라벨


- 무엇을 고장으로 볼 것인가
- 오늘: failure = 1



진행 순서

관측 구간과 예측 구간

과거로 피처를 만들고, 미래로 라벨을 붙입니다.



관측 구간과 예측 구간이 겹치면 누수입니다.



한눈에 비교

Data Mart 체크리스트

모델 전에 다섯 가지를 확인합니다.

확인	내용
단위 · 중복	1행 = 예측 1건, 중복 행이 없는가
누수 컬럼 제거	고장 유형 컬럼(twf~rnf)은 고장 뒤에 기록되는 값
시점	기준 시점 이전에 알 수 있는 값만 쓰는가
라벨 비율	Train·Test의 고장 비율을 확인했는가
재현 코드	만드는 코드를 결과와 함께 저장했는가

핵심 숫자

라벨이 부족한 현장

데이터는 많은데 정답은 적습니다.

학습 구간

8,000 건

마지막 2,000건은 평가용

라벨 있음

780 건

10% (고장 35건)

라벨 없음

7,220 건

검사는 샘플링으로만

실습: 학습 데이터의 라벨 90%를 일부러 숨기고 비교합니다.

핵심 개념

지도 · 비지도 · 준지도

적은 라벨과 많은 무라벨을 함께 씁니다.

01

지도

- 라벨 있는 데이터만
- 정답이 충분할 때

02

비지도

- 라벨 없이 구조 발견
- 2일차 PCA·군집

03


준지도

- 라벨 + 무라벨 모두 활용
- 라벨이 부족할 때

진행 순서

Self-Training 동작 방식

확신 있는 예측부터 정답으로 삼습니다.



실습에서는 확신 90% 이상인 예측만 가짜 라벨로 붙입니다.

핵심 개념

준지도 학습의 주의점

틀린 가짜 라벨은 쌓입니다.

01

기준을 높게

- 확신 기준을 높게 잡기
- 틀린 라벨이 쌓이지 않게

02

드문 고장

- 고장은 정상 쪽으로 쏠림
- 놓치기 쉬움

03

진짜 라벨로 평가

- 평가는 진짜 라벨로만
- 라벨만 쓴 모델과 반드시 비교

이번 실습에서는 Self-Training이 라벨 10%만 쓴 모델과 같은 F1(0.70)이었습니다.

한눈에 비교

하이퍼파라미터란

사람이 정하는 모델 설정값입니다.

모델	하이퍼파라미터	영향
의사결정나무	max_depth, min_samples_leaf	깊을수록 복잡해짐
랜덤포레스트	n_estimators, max_depth	나무 수와 깊이
로지스틱 회귀	C	작을수록 단순해짐

핵심 개념

교차검증

한 번의 분할에 운을 맡기지 않습니다.

01

K-Fold

- 데이터를 K조각으로 나뉘
- 돌아가며 평가

02

Stratified K-Fold

- 불균형에서 비율 유지
- 조각마다 고장이 들어감

03

시간 순서 분할

- TimeSeriesSplit
- 과거로 학습, 미래로 평가

오늘은 Stratified K-Fold(섞음)라 교차검증 F1(0.91)이 Test(0.81)보다 낙관적입니다. 시간 순 교차검증은 6일차에서 다룹니다.

한눈에 비교

탐색 방법

다 해 보거나, 골라서 해 봅니다.

방법	하는 일	주의
Grid Search	모든 조합을 시도	조합이 많으면 느림
Random Search	무작위로 일부만 시도	운이 작용함
자동 탐색	AutoML이 대신 탐색 (6일차)	기본값을 믿지 말 것

핵심 개념

임계값 조정

0.5는 정답이 아닙니다.

01

기본값

- 확률 0.5 이상이면 고장
- 현장 비용과 무관한 값

02

낮추면

- 재현율은 올라가고
- 정밀도는 내려감

03

정하는 곳

- 현장 비용으로 Valid에서
- Test로 정하지 않기


예: 재현율 80% 이상을 지키면서 정밀도가 가장 높은 값



진행 순서

모델 개선 전체 흐름

순서를 지키면 누수가 없습니다.



모델 파일과 함께 임계값, 피쳐 만드는 코드도 저장합니다.



핵심 숫자

워크숍: 반도체 불량률 잡아라

오늘 배운 순서 그대로, 처음 보는 데이터로 불량 예측 모델을 만듭니다.

센서

590 개

SECOM 반도체 공정

생산 기록

1,567 건

시간 순 정렬

불량

104 건

약 6.6%

미션: 불량률 최대한 잡으면서 헛경보를 줄이는 모델을 만들고, 그 근거를 설명합니다.

진행 순서

진행 순서

오늘 배운 순서 그대로 진행합니다.



막히면 기준 모델(3단계)까지만 해도 결과를 정리할 수 있습니다.

한눈에 비교

평가 기준

성능만이 아니라 과정과 해석을 봅니다.

항목	비중	보는 것
성능	40%	Test(시간 순 마지막 20%)의 불량 F1
과정	30%	누수 방지, 시간 분할, 기준 모델과의 비교
해석	30%	지표 선택 근거, 현장 의미

SECOM은 어려운 데이터입니다. 모든 팀이 같은 Test 기간을 쓰며, F1 0.2~0.3도 잘한 것입니다.

핵심 개념

팀 운영

역할을 나누고, 기준 모델부터 만듭니다.

01

역할

- 데이터 담당
- 모델 담당
- 정리·발표 담당

02

시간 배분

- 6교시: 1~4단계
- 7교시: 5~7단계
- 마지막 3분 공유

03

심화 선택

- 빨리 끝난 팀은
- Steel Plates 결함 7종
- 다중 분류에 도전

한눈에 비교

중간 점검 체크리스트

성능보다 먼저 과정이 맞는지 점검합니다.

확인	내용
시간 기준 분할	앞 80% Train, 마지막 20% Test로 나눴는가
Train에서 fit	센서 고르기·결측 처리·스케일링 기준을 Train으로만
리샘플링은 Train만	Pipeline 안에서 적용했는가
기준 모델과 비교	"모두 합격" 모델과 비교했는가
지표	정확도가 아니라 F1·재현율로 보고하는가

핵심 개념

자주 하는 실수

점수가 너무 좋으면 의심하세요.

01

Test로 튜닝

- Test를 보며 설정을 고름
- Test가 Valid처럼 쓰임

02

전체로 전처리

- 전체 데이터로 결측·스케일링
- Test 정보가 섞임

03

정확도만 보기

- 정확도 95%라도
- 불량을 못 잡을 수 있음

한눈에 비교

결과 공유 양식

팀당 3분입니다.


순서	내용	시간
문제와 데이터	무엇을 예측했고, 어떤 점이 어려웠나	30초
접근 방법	분할·센서 정리·불균형 대응·튜닝	1분
결과	혼동행렬·F1, 고른 임계값과 이유	1분
배운 점	다음에 다르게 해 볼 것	30초



진행 순서

오늘 한 일

평가 기준을 세우고, 불균형을 다루고, 누수 없는 표로 모델을 개선했습니다.



한눈에 비교

현장 적용 체크리스트

내 데이터로 해 볼 다섯 가지입니다.

순서	해 볼 일
1	농침·오경보 비용 정리하기
2	고장 비율 확인하기
3	누수 컬럼 점검하기
4	기준 모델 만들기
5	임계값 기준 정하기

한눈에 비교

정리 퀴즈

오늘 배운 것을 다섯 문항으로 확인합니다.

#	질문
1	"정확도 96%"가 왜 함정인가?
2	재현율이란 무엇인가?
3	리샘플링은 어디에 적용하나?
4	과대적합의 신호는?
5	임계값을 낮추면 무엇이 달라지나?

핵심 개념

과제 3

3일차에 만든 고장 예측 모델을 한 단계 더 개선합니다.

01

할 일

- 3일차 모델 개선 (D3_05)
- 임계값을 현장 조건으로
- 불균형 대응 방법 비교

02

제출물

- 분석 노트북 (.ipynb)
- 개선 전후 혼동행렬
- 지표·임계값 선택 근거

03

평가 포인트

- 누수 없이 진행했나
- 기준 모델과 비교했나
- 선택 근거가 분명한가

SECOM 워크숍 모델로 도전해도 좋습니다. 불량이 적어 임계값이 불안정하면 0.5 유지도 결론입니다.

핵심 개념

다음 시간: 4일차 예고

공정 조건으로 품질 수치를 예측할 수 있을까?

01

회귀 모델

- MAE · RMSE · R^2
- 평균 기준선

02

선형 vs ML

- 계수 해석과 다중공선성
- 비선형 관계, 외삽

03

온라인 러닝

- 데이터 드리프트
- Streamlit 예측 앱