

ML이해/분석활용

ML for Analysis

4. 지도학습 : 회귀와 온라인 러닝



한화시스템

DAY 4

지도학습: 회귀와 온라인 러닝

공정 조건으로 품질 수치를 예측할 수 있을까?




ML이해/분석활용 [Level.3] · 6일 과정 · 4일차 · 8교시



진행 순서

오늘의 현장 질문

숫자를 예측하고, 해석하고, 계속 갱신하고, 화면으로 만듭니다.



오늘의 결과물: 강도 예측 모델 + 예측 앱 + 전력 사용량 워크숍 결과



핵심 개념

지난 시간 핵심

오늘 필요한 3일차 개념 세 가지입니다. 회귀에서도 그대로 씁니다.

01

기준 모델부터

- 정확도의 함정
- 기준보다 나은지 확인

02

시간 기준 분할

- 누수 컬럼 제거
- 미래를 보고 배우지 않기

03

교차검증

- 운에 맡기지 않는 평가
- Pipeline으로 누수 방지

한눈에 비교

환경 점검

오늘 쓰는 패키지입니다.

패키지	용도	쓰는 교시
scikit-learn	회귀 모델 · SGDRegressor	전 교시
statsmodels	OLS 결과표 · VIF	2교시
joblib	모델 저장 · 불러오기	5교시
streamlit	예측 앱	5교시

한눈에 비교

오늘의 일정

오전은 이론과 실습, 오후는 팀 워크숍입니다.

교시	주제	교시	주제
1	회귀 개념 · 평가지표 · 기준선	5	Streamlit 예측 앱
2	선형회귀 해석 · 다중공선성	6	워크숍 안내 (전력)
3	선형 vs ML 회귀	7	워크숍 중간 점검
4	드리프트 · 온라인 러닝	8	하루 정리 · 과제 4 안내

매 교시 이론 15분 + 실습·활동 30분 + 휴식 15분입니다.

핵심 개념

회귀 문제란

정답이 숫자인 예측 문제입니다.

01

분류 vs 회귀

- 분류는 범주, 회귀는 숫자
- 고장 여부 vs 강도 수치

02

제조 예

- 콘크리트 강도
- 전력 사용량, 치수

03

평가는 오차

- 얼마나 틀렸는가로 평가
- 맞았다/틀렸다가 아님

한눈에 비교

제조 회귀 활용

측정이 늦거나 비싼 값을 미리 압니다.

활용	입력	출력	효과
가상계측	공정 조건·센서	품질 수치	검사 전 미리 추정
에너지 예측	생산량·시간	전력 사용량	피크 관리
수율 예측	공정 조건	수율(%)	조건 사전 조정
잔여 수명(RUL)	진동·온도 이력	남은 가동 시간	정비 계획

한눈에 비교

평가지표 세 가지

단위로 말하는 MAE, 큰 실수에 엄한 RMSE, 설명력 R^2 입니다.

지표	뜻	특징	읽는 법
MAE	오차 절댓값의 평균	단위가 같아 직관적	평균 몇 MPa 틀리나
RMSE	오차 제곱 평균의 제곱근	큰 실수에 더 엄함	MAE보다 크면 큰 실수 있음
R^2	평균 대비 설명 비율	1에 가까울수록 좋음	0이면 평균 예측과 같음

현장 보고는 단위가 있는 MAE로, 모델 비교는 R^2 와 함께 합니다.

핵심 숫자

기준선: 평균으로 예측하기

평균만 맞혀도 R^2 는 0입니다.

Concrete 데이터

1,030 건

배합 조건 → 압축강도

입력 변수

8 개

시멘트·물·재령 등

평균 예측 R^2

0

모든 모델이 넘어야 할 선

어떤 모델이든 평균 기준선보다 낮지 않으면 쓸 이유가 없습니다.

핵심 개념

오차를 보는 법

숫자 하나보다 그림으로 봅니다.

01

잔차

- 실제 - 예측
- 양수면 과소, 음수면 과대

02

잔차 그래프

- 패턴이 없어야 좋음
- 곡선이 보이면 모델 부족

03

예측-실제 산점도

- 점이 대각선에 모일수록 좋음
- 치우침을 한눈에

핵심 개념

단순회귀 vs 다중회귀

입력 하나 vs 여러 개입니다.

01

단순회귀

- 입력 1개
- 예: 시멘트 → 강도

02

다중회귀

- 입력 여러 개
- 예: 배합 8개 → 강도

03

계수의 뜻

- 다중에서는
- 다른 조건이 같을 때

핵심 개념

계수 해석

계수는 입력 한 단위당 변화입니다.

01

의미

- 시멘트 $1\text{kg}/\text{m}^3$ 늘면
- 강도가 계수만큼 변함

02

단위 문제

- 단위가 다르면 비교 불가
- 표준화 계수로 비교

03

유의성

- 2일차 p-value로
- 우연인지 확인

한눈에 비교

OLS 결과표 읽기

다섯 개만 보면 됩니다.

항목	뜻	볼 점
coef	입력 1단위당 변화량	부호와 크기
std err	계수의 불확실성	작을수록 안정
$P > t $	계수가 우연일 확률	0.05보다 작은가
R-squared	설명 비율	1에 가까운가
Adj. R-squared	변수 수 보정 설명 비율	변수 늘릴 때 비교

핵심 개념

다중공선성

입력끼리 닮으면 계수가 흔들립니다.

01

뜻

- 입력끼리 서로 닮음
- 정보가 겹침

02

증상

- 계수가 불안정
- 부호가 뒤집힘

03

진단 · 대응

- VIF 10 이상이면 의심
- 변수 제거·합치기·규제

한눈에 비교

선형회귀를 믿기 전 확인할 것

네 가지 가정을 점검합니다.

가정	뜻	확인 방법
선형성	관계가 직선에 가까움	잔차 그래프에 곡선 없음
등분산	오차 크기가 일정	잔차 퍼짐이 일정
독립성	오차끼리 무관	시간 순서 패턴 없음
이상치·영향점	소수 값이 결과를 좌우하지 않음	잔차·영향도 확인

가정이 깨지면 계수 해석을 보류하고 변환이나 다른 모델을 검토합니다.

핵심 개념

선형 회귀의 한계

직선으로는 곡선을 못 그립니다.

01

직선 관계만

- 입력과 정답이 직선일 때만
- 곡선은 놓침

02

상호작용 못 봄

- 조건이 겹칠 때 효과
- 따로 만들어야 함

03

재령 예

- 강도는 초기에 빠르게
- 이후 완만하게 증가

한눈에 비교

ML 회귀 모델

트리 기반 모델이 대표적입니다.

모델	특징	주의
의사결정나무	규칙으로 설명	과대적합이 쉬움
랜덤포레스트	성능이 안정적	설명이 어려움
그래디언트 부스팅	높은 성능 (6일차)	튜닝이 필요

한눈에 비교

선형 vs ML 비교

해석이냐 성능이냐입니다.

기준	선형 회귀	ML 회귀
해석	계수로 설명 쉬움	중요도로 간접 설명
비선형 성능	약함	강함
학습 범위 밖	직선을 연장	경계값에서 멈춤
데이터 양	적어도 안정적	많을수록 유리

현장 설명이 필요하면 선형, 정확도가 우선이면 ML입니다. 둘 다 돌려 보고 비교하세요.

핵심 개념

학습 범위 밖 예측(외삽)

모델은 본 적 없는 조건을 모릅니다.

01

트리 모델

- 학습 최댓값 이상은
- 예측하지 못함

02

선형 모델

- 직선을 계속 연장
- 비현실적일 수 있음

03

대응

- 학습 범위를 기록
- 앱에서 경고

핵심 개념

변수 중요도

무엇이 예측에 많이 쓰였나 봅니다.

01

트리 중요도

- 분할에 많이 쓰인 정도
- 계산이 빠름

02

순열 중요도

- 값을 섞었을 때 성능 하락
- 모델과 무관하게 사용

03

주의

- 중요 ≠ 원인
- 상관 변수끼리 나눠 가짐

핵심 개념

모델은 시간이 지나면 늙는다

배포 순간이 가장 정확합니다.

01

원료 로트 변경

- 원료 공급처·로트가 바뀜
- 배합 효과가 달라짐

02

설비 노후

- 마모·정비로 특성 변화
- 같은 조건도 결과가 다름

03

계절·환경

- 온도·습도 변화
- 품질 수치에 영향

한눈에 비교

드리프트의 두 종류

입력이 변하거나, 관계가 변합니다.

종류	뜻	예	탐지
데이터 드리프트	입력 분포가 변함	원료 입도가 달라짐	입력 평균·분포 비교
개념 드리프트	입력-정답 관계가 변함	같은 배합인데 강도 하락	예측 오차 증가

핵심 개념

배치 학습 vs 온라인 러닝

한꺼번에 배우느냐, 조금씩 배우느냐입니다.

01

배치

- 전체 데이터로 학습
- 주기적으로 재학습

02

온라인

- 새 데이터마다 갱신
- 빠르게 변화에 적응

03


현장 조합

- 주기 재학습 +
- 성능 감시

진행 순서

partial_fit 동작 방식

예측하고, 확인하고, 조금 배웁니다.



SGDRegressor는 입력 스케일이 다르면 흔들립니다. 스케일링이 필수입니다.

핵심 개념

온라인 러닝 운영 주의

나쁜 데이터도 그대로 배웁니다.

01

입력 검사

- 이상치·센서 오류 거르기
- 배우기 전에 확인

02

오차 감시

- 1일차 관리도로
- 예측 오차 관리

03


버전 저장

- 갱신 전 모델 보관
- 되돌릴 수 있게

진행 순서

예측 앱 구조

학습은 노트북에서, 예측은 앱에서 합니다.



앱은 학습하지 않고, 저장된 파일을 불러와 예측만 합니다.

핵심 개념

함께 저장할 것

모델 파일 하나로는 부족합니다.

01

모델 + 전처리

- Pipeline으로 함께 저장
- 스케일러 누락 방지

02

입력 컬럼 순서

- 학습 때와 같은 순서
- 이름과 단위 기록

03

메타 정보

- 학습 범위·버전
- 성능(MAE)

한눈에 비교

예측 앱 화면 구성

네 가지 요소면 충분합니다.

요소	Streamlit 함수	역할
입력	st.slider · number_input	배합 조건 입력
결과	st.metric	예측 강도 표시
범위 경고	st.warning	학습 범위 밖 알림
근거	st.bar_chart	변수 중요도 표시

핵심 개념

모니터링과 예측을 하나로

1일차 앱에 오늘 모델을 더합니다.

01

1일차 모니터링

- 현재 상태를 보여줌
- 관리도·KPI

02

오늘 예측

- 앞으로의 품질을 보여줌
- 입력 → 예측값

03

예측 오차 관리도

- 모델 상태를 감시
- 드리프트 조기 발견

핵심 숫자

워크숍: 제철소 전력 사용량 예측

국내 제철소의 1년 치, 15분 단위 전력 데이터입니다.

전체 기록

35,040 건

2018년 1년 치

측정 간격

15 분

하루 96건

예측 대상

kWh

Usage_kWh 회귀

미션: 시간 순서를 지키며 전력 사용량을 예측하세요.



진행 순서

진행 순서

오늘 배운 순서 그대로 진행합니다.



날짜를 변환해 시간 순으로 정렬하세요. 원본은 00:00 기록이 하루 끝에 붙어 있습니다.



한눈에 비교

평가 기준

성능만이 아니라 과정과 해석을 봅니다.

항목	비중	보는 것
성능	40%	Test(시간 순 마지막 20%)의 MAE
과정	30%	누수 점검, 시간 분할, 기준선 비교
해석	30%	중요 변수, 현장 의미



핵심 개념

이 데이터의 함정

정답을 담은 컬럼을 찾아라

01

누수 컬럼

- CO2: 사용량에서 환산됨
- 무효전력·역률도 제외

02

시간 피쳐

- 시각·요일·주중/주말
- 부하 유형 활용

03

분할 금지

- 무작위 분할 금지
- 시간 순 80/20

상관계수와 시험 모델로 직접 확인하세요. CO2만 빼도 R^2 가 약 1.0입니다.



한눈에 비교

중간 점검 체크리스트

R^2 가 0.99라면 기뻐하기 전에 누수를 의심합니다.

확인	내용
시간 분할	앞 80% Train, 마지막 20% Test로 나눴는가
누수 컬럼 제외	CO2·무효전력·역률을 입력에서 뺐는가
평균 기준선	평균 예측 MAE와 비교했는가
Train에서 fit	전처리 기준을 Train으로만 잡았는가
MAE 해석	kWh 단위로 현장 의미를 설명하는가

핵심 개념

자주 하는 실수

점수가 너무 좋으면 의심하세요.

01

일부만 제외

- CO2만 빼고
- 무효전력·역률 포함

02

무작위 분할

- 앞뒤 시간이 섞임
- 미래 정보가 새어들

03

R^2 만 보기

- R^2 가 높아도
- MAE가 크면 쓸 수 없음

한눈에 비교

결과 공유 양식


팀당 3분입니다.

순서	내용	시간
문제와 데이터	무엇을 예측했고, 어떤 점이 어려웠나	30초
접근 방법	누수 점검·분할·모델 비교	1분
결과	MAE와 예측-실제 그래프	1분
배운 점	다음에 다르게 해 볼 것	30초

진행 순서

오늘 한 일

평가하고, 해석하고, 비교하고, 갱신하고, 앱으로 만들었습니다.



한눈에 비교

현장 적용 체크리스트

내 데이터로 해 볼 다섯 가지입니다.

순서	해 볼 일
1	예측하고 싶은 품질값 정하기
2	평균 기준선 MAE 구하기
3	선형회귀 계수 해석해 보기
4	학습 범위 기록하기
5	예측 오차 추이 그려 보기

한눈에 비교

정리 퀴즈

오늘 배운 것을 다섯 문항으로 확인합니다.

#	질문
1	MAE와 RMSE는 무엇이 다른가?
2	R^2 가 0이라는 것은 무슨 뜻인가?
3	다중공선성의 증상은?
4	트리 모델은 학습 범위 밖을 왜 못 맞히나?
5	데이터 드리프트와 개념 드리프트의 차이는?



핵심 개념

과제 4

워크숍 전력 모델을 개선하고 예측 앱을 만듭니다.

01

할 일

- 전력 모델 개선
- 콘크리트 앱 참고해 앱 제작
- 1일차 앱과 st.tabs로 합치기

02

제출물

- 분석 노트북 (.ipynb)
- 앱 .py
- 개선 전후 MAE

03

평가 포인트

- 누수 없이 진행했나
- 기준선과 비교했나
- 범위 경고가 동작하나

숫자 입력 피쳐 1개 이상(예: 7일 전 같은 시각 사용량)이 있어야 범위 밖 경고가 울립니다.



핵심 개념

다음 시간: 5일차 예고

다음 주 전력 사용량은?

01

시계열 분해

- 추세·계절·잔차
- 워크숍 데이터를 시계열로

02

ARIMA · SARIMA

- 과거 값으로 미래 예측
- 계절성 반영

03

ML 시계열

- 지연값 피쳐 활용
- 시간 순 평가