

ML이해/분석활용

ML for Analysis

6. 고급 머신러닝 및 AutoML



한화시스템

DAY 6

고급 머신러닝 및 AutoML

모델을 더 강하게, 더 빠르게 만들려면?




ML이해/분석활용 [Level.3] · 6일 과정 · 6일차 · 8교시



진행 순서

오늘의 현장 질문

오전에는 앙상블과 AutoML, 오후에는 팀 프로젝트입니다.



오늘의 결과물: 앙상블 비교 결과 + PyCaret 워크숍 모델 + 팀 발표





핵심 개념

지금까지의 핵심

오늘 워크숍에 필요한 3~5일차 개념입니다. 공통은 시간 순 분할과 누수 점검입니다.

01

분류

- 재현율 · F1
- 불균형 대응

02

회귀

- MAE로 오차 해석
- 학습 범위 밖 주의

03

시계열

- Walk-forward 평가
- 계절 naive 기준선



한눈에 비교

환경 점검

PyCaret이 동작하는지 먼저 확인합니다.

항목	요구 사항	확인 방법
Python	3.11 가상환경	<code>python --version</code>
pycaret	3.3.2	<code>import pycaret</code>
lightgbm	설치됨	<code>import lightgbm</code>

한눈에 비교

오늘의 일정

오전은 이론과 실습, 오후는 워크숍과 발표입니다.

교시	주제	교시	주제
1	앙상블 개요 · 배깅	5	최종 워크숍 안내
2	부스팅	6	워크숍 중간 점검
3	블렌딩 · 스택킹	7	발표 및 리뷰
4	AutoML과 PyCaret	8	과정 총정리

매 교시 이론 15분 + 실습·활동 30분 + 휴식 15분입니다.

핵심 개념

앙상블이란

여러 모델의 의견을 모읍니다.

01

집단 지성

- 한 모델보다 여럿이
- 더 안정적

02

실수가 상쇄

- 서로 다른 실수를
- 서로 덮어 줌

03

조건

- 모델들이 서로 달라야 함
- 똑같으면 효과 없음

한눈에 비교

앙상블 세 갈래


나란히, 차례로, 위에 쌓습니다.

방식	방법	줄이는 것	대표 모델
배깅	나란히 학습해 평균	흔들림(분산)	랜덤포레스트
부스팅	차례로 학습해 보완	치우침(편향)	LightGBM
스태킹	예측을 다시 학습	단일 모델 한계	StackingClassifier

진행 순서

배깅 동작 방식

뽑고, 각자 배우고, 모읍니다.



데이터를 조금씩 다르게 뽑아 서로 다른 모델을 만드는 것이 핵심입니다.

핵심 개념

랜덤포레스트

배깅에 변수 무작위까지 더합니다.

01

데이터 무작위

- 부트스트랩으로 뽑음
- 나무마다 데이터가 다름

02

변수 무작위

- 나눌 때마다
- 일부 변수만 후보

03

OOB 점수

- 뽑히지 않은 데이터로
- 따로 검증

핵심 개념

배깅이 주는 것

흔들림을 줄입니다.

01

분산 감소

- 예측이 안정적
- 데이터가 바뀌어도 비슷

02

과대적합 완화

- 깊은 나무도
- 덜 외움

03

병렬 학습


- 나무를 동시에 학습
- 속도가 빠름



진행 순서

부스팅 아이디어

앞 모델이 틀린 부분을 다음 모델이 보완합니다.



정형 데이터에서 가장 강한 방법 중 하나입니다.



한눈에 비교

AdaBoost vs GBM

GBM은 Gradient Boosting입니다. 가중치로 보완하느냐, 잔차로 보완하느냐입니다.

방식	보완 방법	특징
AdaBoost	틀린 데이터에 가중치	단순, 이상치에 민감
Gradient Boosting	남은 오차를 다음 모델이 학습	유연, 성능 높음

한눈에 비교

대표 구현

빠르고 강한 세 가지입니다.

구현	특징	강점
XGBoost	부스팅의 표준	안정적, 자료 많음
LightGBM	속도가 빠름	대용량 데이터
CatBoost	범주형 변수 처리	전처리 적게

한눈에 비교

핵심 하이퍼파라미터

네 가지만 기억합니다.

이름	뜻	키우면
n_estimators	모델(나무) 개수	성능↑ 후 과대적합
learning_rate	한 번에 배우는 크기	빠르지만 거칠어짐
max_depth·num_leaves	나무 복잡도	복잡해져 외움
조기 종료	개선 없으면 멈춤	과대적합 방지

한눈에 비교

배깅 vs 부스팅

언제 무엇을 쓸지 정리합니다.

기준	배깅	부스팅
학습 방식	나란히(병렬)	차례로(순차)
줄이는 것	흔들림(분산)	치우침(편향)
과대적합 위험	낮음	높음, 조절 필요
속도	병렬이라 빠름	순차라 느림
튜닝 난이도	쉬움	어려움

핵심 개념

블렌딩(보팅)

가장 간단한 섞기입니다.

01

하드 보팅

- 모델들이 다수결로
- 클래스를 결정

02

소프트 보팅

- 확률을 평균
- 임계값 조정에 유리

03

회귀

- 예측값을 평균
- 가장 단순한 앙상블

구조 한눈에

스택킹 구조

기본 모델의 예측을 메타러너가 다시 학습합니다.




서로 다른 종류의 모델을 기본 모델로 쓸수록 효과가 큽니다.



진행 순서

스택킹의 누수 함정

메타러너는 처음 보는 예측으로 배워야 합니다.



Train 예측으로 메타러너를 배우면 누수입니다. 그래서 OOF를 씁니다.



핵심 개념

스택킹, 언제 쓸까

마지막 몇 %가 필요할 때 씁니다.

01

다양성

- 서로 다른 모델일수록
- 효과가 큼

02

기대 효과

- 성능 향상은
- 대개 작음

03

비용

- 학습이 느리고
- 설명이 어려움

핵심 개념

AutoML이란

반복은 기계가, 판단은 사람이 합니다.

01

자동

- 전처리 · 모델 비교
- 튜닝

02

사람

- 문제 정의 · Data Mart
- 누수 점검 · 해석

03


장단점

- 장점: 빠른 탐색
- 한계: 블랙박스

진행 순서

PyCaret 작업 흐름

여섯 개 함수면 됩니다.



가장 중요한 것은 첫 번째 **setup**입니다. 분할과 누수가 여기서 정해집니다.

한눈에 비교

setup에서 정하는 것

가장 중요한 한 줄입니다.

옵션	역할	비고
target · test_data	정답 열, 마지막 20% Test	시간 순 분할
fold_strategy='timeseries'	시간 순 교차검증	data_split_shuffle=False와 함께
ignore_features	누수 컬럼 제외	사람이 직접 지정
fix_imbalance · session_id	불균형 처리, 재현성	분류에서 사용
normalize · n_jobs=1	단위가 제각각일 때, 블렌딩 오류 방지	SECOM 등 데이터에 따라

한눈에 비교

세 가지 모듈

분류, 회귀, 시계열입니다.

모듈	맞는 문제	오늘 트랙
classification	범주 예측	AI4I 고장, 트랙 A (SECOM)
regression	숫자 예측	트랙 B (전력 kWh)
time_series	시간 순 예측	트랙 C (일별 전력)

한눈에 비교

지금까지 배운 것이 PyCaret에서

손으로 했던 것이 옵션으로 있습니다.

배운 것	PyCaret 기능	주의
2일차 누수 제거	ignore_features	직접 지정
3일차 불균형	fix_imbalance	Train에만 적용
3일차 교차검증	fold 설정	시간 순 fold로 바꿈
오늘 앙상블	blend·stack	비교 후 선택
4일차 저장	save_model	Pipeline 포함 저장

핵심 개념

AutoML의 함정

기본값을 믿지 마세요.

01

무작위 분할

- 기본값은 섞어서 나눔
- 시간 누수가 생김

02

누수 컬럼

- 자동으로 거르지 못함
- 사람이 직접 점검

03

1위 맹신 금지

- 차이가 작으면
- 단순한 모델 선택

핵심 개념

최종 워크숍: 트랙 고르기

세 가지 트랙 중 하나를 고릅니다.

01

A 분류

- SECOM 불량 예측
- 지표: 불량 F1

02

B 회귀

- 제철소 전력 Usage_kWh
- 지표: MAE(kWh)

03


C 시계열

- 일별 전력 7일 예측
- 계절 naive 이기기

진행 순서

진행 순서

6일 과정을 한 번에 돌아봅니다.



막히면 기준 모델과 PyCaret 1위까지만 해도 결과를 정리할 수 있습니다.

한눈에 비교

평가 기준

성능, 과정, 해석, 발표를 봅니다.

항목	비중	보는 것
성능	30%	Test(시간 순 마지막 20%) 지표
과정	30%	누수 점검, 분할, 기준선 비교
해석·현장 적용	20%	중요 변수, 현장 의미
발표	20%	전달력, 질의응답

성능 지표는 A 불량 F1, B MAE(kWh), C 계절 naive 대비 MAE 개선입니다.

핵심 개념

팀 운영

역할과 시간을 나눕니다.

01

역할

- 데이터 담당
- 모델 담당
- 발표 담당

02

시간 배분

- 5교시: 모델 만들기
- 6교시: 개선과 발표 자료
- 7교시: 발표

03

막히면

- 기준 모델부터
- PyCaret 1위로 정리

한눈에 비교

중간 점검 체크리스트

자동화가 빠른 만큼 실수도 빠르게 퍼집니다.

확인	내용
시간 순 Test	마지막 20%를 Test로 지켰는가
누수 컬럼 제외	정답을 담은 컬럼을 뺐는가
기준 모델 비교	기준선보다 나은가
1위 모델 선택	고른 이유를 설명할 수 있는가
발표 자료	5장 구성이 진행 중인가

핵심 개념

자주 하는 실수

AutoML에서 특히 많은 실수입니다.

01

기본 설정 그대로

- 무작위 분할 상태로
- 결과를 해석함

02

표만 붙여넣기

- compare 표를
- 설명 없이 제출

03

앙상블 맹신

- 앙상블이 항상
- 낫다고 가정

한눈에 비교

발표 자료 구성

슬라이드 5장이면 충분합니다.

순서	내용
1 문제 정의	무엇을 예측하고 왜 필요한가
2 데이터·누수 점검	데이터 설명, 제외한 컬럼
3 접근 방법	분할·모델·PyCaret 설정
4 결과	지표, 기준선 대비 개선
5 현장 적용 제안	어떻게 쓸 수 있을까

한눈에 비교

발표 진행 방식

팀당 7분입니다.

항목	내용
시간	발표 5분 + 질의응답 2분
순서	트랙·팀 순서대로
듣는 팀의 역할	팀마다 질문 1개씩

한눈에 비교

평가표


듣는 팀이 쓰는 동료 평가표입니다. 다섯 항목, 각 5점입니다.

항목	보는 것
문제 정의	무엇을 왜 예측하는가
과정의 타당성	분할·누수 점검이 맞는가
결과 해석	숫자의 의미를 설명하는가
현장 적용성	현장에서 쓸 수 있는가
전달력	명확하게 설명하는가

진행 순서

6일 동안 한 일

데이터에서 모델, 그리고 현장까지 왔습니다.



한눈에 비교

현장 ML 프로젝트 체크리스트

열 단계를 네 묶음으로 순서대로 밟습니다.

묶음	단계
준비	문제 정의 · 데이터 흐름 · Data Mart · EDA
설계	데이터 분할 · 기준선
모델링	모델 선택 · 평가 지표
해석·운영	해석 · 운영 · 모니터링

핵심 개념

꼭 기억할 세 가지

6일 과정의 핵심 원칙입니다.

01

기준선부터

- 평균·naive보다
- 나은지 먼저

02

누수를 의심

- 점수가 너무 좋으면
- 정답 컬럼을 찾기

03

현장 비용으로

- 지표는 놓침·오경보
- 비용으로 고르기

핵심 개념

다음 단계

여기서 더 나아가려면 이렇게 하세요.

01

딥러닝

- 이미지 · 센서 시계열
- 더 복잡한 패턴

02

MLOps

- 배포·모니터링 자동화
- 모델 관리

03

내 현장에서

- 내 데이터로
- 작은 프로젝트 하나

THANK YOU

6일 과정을 마칩니다

현장의 질문을 데이터로 풀어 보세요



ML이해/분석활용 [Level.3] · 6일 과정 · 수료